

# ImageRecognition aiheäärittely (tarkentuu)

Simo Korkolainen

30. toukokuuta 2016

Projektin tarkoituksena on tehdä ohjelma, joka opettaa neuroverkon tunnistamaan kuvia backpropagation-algoritmin avulla. Neuroverkon opetuksessa verkon painoja muutetaan liikuttamalla niitä virhefunktion gradientin vastaiseen suuntaan, kunnes virhefunktio on minimoitunut ja neuroverkko on oppinut tunnistamaan kuvat. Derivoinnin ketjusääntöön perustuva backpropagation-algoritmi mahdollistaa gradientin nopean laskemisen.

## 1 Neuroverkko

Neuroverkko koostuu kerroksista, joissa on neuroneita. Olkoon  $L$  neuroverkon kerroksien lukumäärä. Olkoon  $l_k$  kerroksen  $k = 1, \dots, L$  neuronien lukumäärä. Merkitään kerroksen  $k$  aktivaatiota vektorina  $z_k \in \mathbb{R}^{l_k}$ . Ensimmäisen kerroksen aktivaatio  $z_1$  on neuroverkon syöte ja viimeisen kerroksen aktivaation  $z_L$  on neuroverkon antama tuloste.

Jokaisen kerroksen  $k > 1$  aktivaation voidaan ajatella laskettavan parametrisoidun funktion  $f_k : \mathbb{R}^{l_{k-1}} \times A_k \rightarrow \mathbb{R}^{l_k}$  avulla. Tässä  $A_k$  on verkon kerroksien  $k-1$  ja  $k$  yhteyksien painoina toimivien parametrien joukko. Kerroksen aktivaatio lasketaan rekursiivisesti kaavan

$$z_k = f(z_{k-1}, a_k)$$

avulla, missä  $a_k \in A_k$ . Parametrit  $a_1, \dots, a_L$  on tarkoitus oppia backpropagation-algoritmia käyttäen.

## 2 Aineisto ja kokonaisvirhe

Olkoon  $x_1, x_2, \dots, x_n \in \mathbb{R}^{l_1}$  neuroverkon opetussyötteitä ja  $y_1, y_2, \dots, y_n \in \mathbb{R}^{l_L}$  syötteitä vastaavia tavoitetuloksia. Olkoon  $E : \mathbb{R}^{l_L} \times \mathbb{R}^{l_L} \rightarrow \mathbb{R}$  virhefunktio. Merkitään syötteen  $x_j$  aiheuttamaa aktivaatiota kerroksessa  $k$  merkinnällä  $z_k^j$ , jolloin syötekerroksessa pätee  $z_1^j = x_j$ . Määritellään neuroverkon kokonaisvirhe kaavalla

$$E_{tot} = \sum_{j=1}^n E(z_L^j, y_j).$$

Backpropagation-algoritmin tarkoituksena on valita parametrin  $a_1, \dots, a_L$  siten, että kokonaisvirhe  $E_{tot}$  minimoituu.

Jos neuroverkkoa käytetään syötteiden luokitteluun erillisiin luokkiin  $1, \dots, S = l_L$ , viimeisen kerroksen  $z_L = (z_{L1}, \dots, z_{LS})$  aktivaation  $z_{Lm}$  tulkitaan tarkoittavan todennäköisyyttä, että syöte  $x_j$  kuuluu luokkaan  $m$ . Halutuksi tulokseksi valitaan  $y_{jm} = 1$ , kun  $x_j$  kuuluu luokkaan  $m$  ja  $y_{jm} = 0$  muulloin. Luokittelun tapauksessa on luontevaa käyttää viimeisessä kerroksessa softmax-funktiota  $f_L : \mathbb{R}^S \times A_L \rightarrow (0, 1)^S$ , missä

$$f_{Lm}(z_{L-1}) = \frac{e^{\sum_{i=1}^{l_{L-1}} a_{mi} z_{(L-1)i}}}{\sum_{k=1}^S e^{\sum_{i=1}^{l_{L-1}} a_{ki} z_{(L-1)i}}}.$$

Softmax-funktion kuva-alkion komponenttien summa on yksi.

Luokittelussa virhefunktiona käytetään yleensä logloss-virhettä. Tässä tapauksessa virhefunktio määritellään kaikilla  $s \in \{0, 1\}^S$  ja  $t \in (0, 1)^S$  kaavalla

$$E(s, t) = \sum_{m=1}^S s_m \log(t_m).$$

### 3 Backpropagation-algoritmi

### 4 Aikavaativuus

Neuroverkoon liittyvät aikavaativuudet riippuvat paljon neuroverkon rakenteesta. Ohjelmassa käytetään vain eteenpäin kytkettyjä neuroverkkoja. Neuronien aktivaatio  $z_k$  kerroksessa  $k$  lasketaan täsmälleen edellisen kerroksen aktivaatioiden perusteella eli  $z_k = f(z_{k-1}, a_k)$  missä  $f$  on aktivaatiofunktio. Kuten aikasemmin, olkoon  $L$  neuroverkon kerroksien lukumäärä ja olkoon  $l_k$  kerroksen  $k = 1, \dots, L$  neuronien lukumäärä. Jos jokainen kerroksen  $k$  neuroni on kytketty kaikkiin edellisen kerroksen solmuihin ja neuronipariin liittyvän laskennan aikavaativuus on luokkaa  $O(1)$ , yhden kerroksen  $k$  neuronin aktivaation laskemisen aikavaativuus on luokkaa  $O(l_{k-1})$ . Koska kerroksessa  $k$  on  $l_k$  neuronia, koko kerrokseen liittyvän laskennan aikavaativuus on  $O(l_{k-1}l_k)$ . Ensimmäisen kerroksen eli syötekerroksen aktivaatioiden asettamisen aikavaativuus on  $O(l_1)$ .

Koko neuroverkon aktivaatioiden laskennan aikavaativuus  $T_{act}$  on kerrosten aikavaativuuksien summa eli

$$T_{act} = O(l_1 + \sum_{k=2}^L l_{k-1}l_k)$$

Tarkastellaan tapausta, jossa kerrosten neuronien lukumäärä pienenee eksponentiaalisesti eli  $l_k = \alpha^{k-1}l_1$ , missä  $0 < \alpha < 1$ . Tällöin

$$\begin{aligned} l_1 + \sum_{k=2}^L l_{k-1}l_k &= l_1 + \sum_{k=2}^L \alpha^{k-2}l_1\alpha^{k-1}l_1 \\ &= l_1 + l_1^2 \sum_{k=2}^L \alpha^{2k-3} \\ &= l_1 + l_1^2 \alpha \sum_{k=0}^{L-2} (\alpha^2)^k \\ &\leq l_1 + l_1^2 \alpha \sum_{k=0}^{\infty} (\alpha^2)^k \\ &= l_1 + l_1^2 \frac{\alpha}{1-\alpha^2} \end{aligned}$$

Saamme, että  $T_{act} = O(l_1^2)$ , koska  $\frac{\alpha}{1-\alpha^2}$  on positiivinen vakio.